

Grands models de langages (LLM)

TALN Semaine 8

Merci à Dan Jurafsky et Marius Mosbach pour certaines des diapositives de cette semaine !

Plan pour aujourd'hui

1. Que sont les grands models de langage (LLMs)?
2. Pré-entraînement et peaufinage
3. Échantillonnage et décodage : Comment fonctionne la génération de texte
4. Prompting : toutes les tâches en tant que génération de texte à texte
5. Évaluation des LLM
6. *Discussion de groupe: Impacts - Risques des LLMs et l'imputabilité*

Large language models

LARGE language models, Les LM à grande échelle.

En pratique : Agents informatiques qui peuvent interagir de manière conversationnelle avec des personnes utilisant un langage naturel

Les LLM ont révolutionné le domaine de TALN et de l'IA

Intuition fondamentale des LLM (pourquoi plus gros?)

Intuition fondamentale des LLM (pourquoi plus gros?)

Le texte contient d'énormes quantités de connaissances


La pré-entraînement sur beaucoup de texte avec toutes ces connaissances est ce qui donne aux LLM leur capacité à faire autant.

Qu'est ce qu'un LLM?


Un réseau neuronal:

Input: context ou préfixe,

Output: une distribution le possible prochain mot




Trois architectures de grands modèles de langage



Decodeurs


GPT, Claude,
Llama

Mixtral



Encodeurs


BERT family,
HuBERT



Encodeur-décodeurs

Flan-T5, Whisper

Decodeurs




Ce à quoi la plupart des gens pensent quand nous disons LLM


- GPT, Claude, Llama, DeepSeek, Mistral
- Un modèle génératif
- Il prend comme entrée une série de tokens et génère de manière itérative un token de sortie un à la fois.
- De gauche à droite (causal, autorégressif)

Encodeurs

- Masked Language Models (MLMs)
- Famille de modèles comme BERT
- Entraînés en prédisant les mots utilisant les mots environnants des deux côtés (bidirectionnels)
- Sont généralement peaufinés pour les tâches de classification sur les données supervisées.



Encodeur-Dcodeurs




- Formé à correspondre d'une séquence à une autre
- Très populaire pour :
 - Traduction automatique (d'une langue à l'autre)
 - Reconnaissance vocale (de l'acoustique aux mots)

Aujourd'hui: modèles de décodeur uniquement


Aussi nommés

- Causal LLMs
- Autoregressive LLMs
- Left-to-right LLMs




Pré-entraînement et peaufinage des LLM

Trois étapes d'entraînement des LLM



Trois étapes d'entraînement des LLM



Pré-entraînement

La grande idée qui sous-tend toutes les performances étonnantes des LLM

D'abord **Pré-entraînez** un modèle de transformer sur d'énormes quantités de données

Ensuite, appliquez-le à de nouvelles tâches via **peaufinage**

Qu'est-ce qu'un modèle apprend du pré-entraînement?

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was _____

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was enormous

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was enormous
- The square root of 4 is _

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was enormous
- The square root of 4 is 2

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was enormous
- The square root of 4 is 2
- The author of "A Room of One's Own" is Virginia

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was enormous
- The square root of 4 is 2
- The author of "A Room of One's Own" is Virginia Woolf

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was enormous
- The square root of 4 is 2
- The author of "A Room of One's Own" is Virginia Woolf
- The professor told me that ____

Qu'est-ce qu'un modèle apprend du pré-entraînement?

- With roses, dahlias, and peonies, I was surrounded by flowers
- The room wasn't just big it was enormous
- The square root of 4 is 2
- The author of "A Room of One's Own" is Virginia Woolf
- The professor told me that he

Rappel : Algorithme de formation auto-supervisé

Nous les entraînons simplement à prédire le mot suivant !

1. Prenez un corpus de texte
2. À chaque étape t
 - i. Demandez au modèle de prédire le mot suivant
 - ii. Entraînez le modèle en utilisant la descente du gradient pour minimiser l'erreur dans cette prédiction

"Auto-supervisé" parce qu'il utilise juste le mot suivant comme étiquette !

Rappel : perte d'entropie croisée pour la modélisation du langage

CE loss: Différence entre la vraie distribution de probabilité et la distribution prédite


$$L_{CE} = - \sum_{w \in V} \mathbf{y}_t[w] \log \hat{\mathbf{y}}_t[w]$$

La vraie distribution $\mathbf{y}_t$ connaît le mot suivant, donc 1 pour le mot suivant réel et 0 pour les autres. (One-hot)

Donc, dans cette somme, tous les termes sont multipliés par zéro sauf un : le logprob que le modèle attribue au mot suivant réel, donc :

$$L_{CE}(\hat{\mathbf{y}}_t, \mathbf{y}_t) = -\log \hat{\mathbf{y}}_t[w_{t+1}]$$

Entraîner d'un modèle de langage de transformer



LLM principalement formés sur des données du web

Common crawl, snapshots du web en son entièreté produit par l'OBNL Common Crawl avec de milliards de page.

Colossal Clean Crawled Corpus (C4; [Raffel et al. 2020](#)), 156 milliards de tokens en anglais, filtré


Qu'y a-t-il dedans ? Principalement des documents textuels brevetés, Wikipédia et sites d'information

The Pile: a pre-training corpus

academics

web

books



dialog

Filtrage pour la qualité et la sécurité

La qualité est subjective


- De nombreux LLM tentent de faire correspondre Wikipédia, des livres, des sites Web particuliers
- Besoin de retirer le contenu boilerplate, contenu pour adultes
- Déduplication à plusieurs niveaux (URL, documents, même des lignes)

La sécurité est également subjective

- La détection de la toxicité est importante, bien que cela ait des résultats mitigés
- Peut signaler par erreur des données écrites dans des dialectes comme l'anglais afro-américain
- Différences culturelles par rapport à la censure

What's in my big data?


Elazar et al. (2024) - What's in my big data?



OpenWebText		C4		mC4-en		OSCAR		The Pile	
<i>n</i> -gram	Count	<i>n</i> -gram	Count	<i>n</i> -gram	Count	<i>n</i> -gram	Count	<i>n</i> -gram	Count
-----	3.4M	????????	9M	-----	1.76B	-----	773M	-----	3.64B
-----	1.05M	-----	7.27M	-----	823M	////////	395M	=====	602M
=====	830K	-----	4.41M	????????	349M	-----	175M	*****	188M
*****	595K	*****	3.87M	*****	314M	-----	91.6M	{ ref - type = " fig " }	59.1M
#####	302K	!!!!!!!	1.91M	\\s\\files\\1\\	183M	*****	34.9M	////////	56.2M
amp ; amp ; amp ; amp ;	278K	. You can follow any responses to this entry through	784K	/s\\files\\1\\	183M	=====	22.9M	-----	54.9M
; amp ; amp ; amp ; amp	265K	???	753K	\\\\cdn.shopify.com\\s\\	182M	(Opens in new window) Click to share on	15.7M	#####	38.3M
-----	249K	You can follow any responses to this entry through the	752K	/cdn.shopify.com\\s\\files\\	182M	Log Out / Change) You are commenting using your	13.6M	}-----	30.1M
-----	88.1K	can follow any responses to this entry through the RSS	752K	\\\\cdn.shopify.com\\s\\files\\	182M	(Log Out / Change) You are commenting using	13.6M	{ ref - type = " fig " }	28.9M
~~~~~	83.3K	follow any responses to this entry through the RSS 2.0	748K	/\\\\cdn.shopify.com\\s\\files	182M	. ( Log Out / Change ) You are commenting	13.6M	}=====	21.8M
RedPajama		S2ORC		peS2o		LAION-2B-en		The Stack	
<i>n</i> -gram	Count	<i>n</i> -gram	Count	<i>n</i> -gram	Count	<i>n</i> -gram	Count	<i>n</i> -gram	Count
-----	670M	q q q q q q q q q	30.2M	-----	1.42M	-----	1.65M	-----	4.29B
-----	507M	-----	5.49M	[ 1 ] [ 2 ] [ 3 ] [	457K	???	1.43M	*****	3.87B
////////	213M	+++++	3.03M	1 [ 2 ] [ 3 ] [ 4 ]	453K	-----	1.15M	0 0 0 0 0 0 0 0	2.75B
*****	195M	*****	1.93M	1 [ 2 ] [ 3 ] [ 4 ]	453K	////////	809K	=====	2.62B
=====	145M	o o o o o o o o o	1.73M	[ 5 ] [ 6 ] [ 7 ] [	450K	< br /> < br /> < br />	797K	, " resolved " : " https : //	1.46B
////////	79.3M	-----	1.56M	[ 6 ] [ 7 ] [ 8 ] [	448K	/> < br /> < br />	796K	, " resolved " : " https : /	1.46B
./././././	35.3M	-----	1.11M	1 [ 6 ] [ 7 ] [ 8 ]	448K	br /> < br /> < br />	796K	" resolved " : " https : // registry.npmjs.org	1.42B
./././././	35.3M	[ 5 ] [ 6 ] [ 7 ] [	646K	5 [ 6 ] [ 7 ] [ 8 ]	446K	> < br /> < br /> < br />	576K	resolved " : " https : // registry.npmjs.org /	1.42B
./././././	35.2M	[ 1 ] [ 2 ] [ 3 ] [	645K	1 [ 7 ] [ 8 ] [ 9 ]	446K	Price : 1 Credit ( USD \$ 1 )	437K	.....	1B
#####	33M	[ 6 ] [ 7 ] [ 8 ] [	644K	6 [ 7 ] [ 8 ] [ 9 ]	444K	vector   Price : 1 Credit ( USD \$ 1	437K	. tgz " , " integrity " : " sha512	938M

# What's in my big data?

Elazar et al. (2024) - What's in my big data?



# **Mais il y a des problèmes avec le scrapping du web**

## **Copyright**

- Une grande partie du texte de ces ensembles de données est protégée par le droit d'auteur
- Cela reste une question juridique ouverte

## **Consentement du partage des données**

- Les propriétaires de sites Web ne peuvent pas indiquer s'il sont d'accord que leur site soit inclu dans le crawl


## **Confidentialité**

- Les sites Web peuvent contenir des adresses IP privées et des numéros de téléphone

## **Bias**

- Les données de formation sont générées de manière disproportionnée par des auteurs des États-Unis, ce qui fausse probablement les sujets et les opinions qui en résultent

# Trois étapes d'entraînement des LLM




# Peaufinage pour l'adaptation à de nouveaux domaines

Que se passe-t-il si nous avons besoin que notre LLM fonctionne bien dans un domaine qu'il n'a pas vu lors du pré-entraînement ?

Peut-être un domaine médical ou juridique spécifique ?

Ou peut-être qu'un modèle multilingue doit voir plus de données dans une langue qui était rare lors du pré-entraînement ?

# Peaufinage (Peaufinage)



« Peaufinage » peut vouloir dire 4 choses différentes

Nous en verrons 1 ici, et 3 à la semaine 11

Dans les quatre cas, le peaufinage signifie :

**prendre un modèle pré-entraîné et adapter  
davantage certains ou tous ses paramètres à de  
nouvelles données**


# 1. Peaufinage comme « pré-entraînement poursuivi » sur de nouvelles données

- Entraîner davantage tous les paramètres du modèle sur de nouvelles données
  - en utilisant la même méthode (prédiction de mots) et la même fonction de perte (entropie croisée) que pour le pré-entraînement.
  - comme si les nouvelles données se trouvaient à la fin des données de pré-entraînement
- D'où parfois appelé **continued pretraining**

**Une fois qu'un modèle est entraîné, comment peut-on générer du texte à partir de celui-ci?**

# Échantillonnage : comment fonctionne la génération de texte

Un modèle fournit une distribution de probabilité sur les prochains mots, nous générons en échantillonnant à plusieurs reprises à partir de la distribution conditionnelle.



# Génération conditionnelle : Génération de texte conditionné sur le texte précédent !

1. Donnez au LLM un morceau de texte en entrée, un **prompt**
2. Faites-le générer token par token
  - conditionné par le prompt et les tokens déjà générés

Nous générons à partir d'un modèle en


1. calculant la probabilité du prochain token  $w_i$  du context précédant:  $P(w_i | w_{<i})$
2. échantillonnant de cette distribution pour générer un token

# D'où vient la probabilité d'un token ?


Les réseaux internes des LLM génèrent des scores appelés **logits** pour chaque token du vocabulaire.

Le vecteur de scores **u** of shape  $[1 \times |V|]$  est converti en probabilité par la fonction softmax

$$\mathbf{y} = \text{softmax}(\mathbf{u})$$



# Génération conditionnelle : Génération de texte conditionné sur le texte précédent !



# Décodage

La tâche qui consiste à choisir un mot à générer sur la base des probabilités du modèle s'appelle **le décodage**.

Décoder un modèle de gauche à droite et choisir à répétition le prochain token en fonction de nos choix précédents s'appelle **génération autorégressive**.

# Décodage glouton


Un **algorithme glouton** est un algorithme qui fait un choix localement optimal

- (Que cela s'avère ou non avoir été le meilleur choix avec le recul)

Il suffit de générer le mot le plus probable :

$$\hat{w}_t = \operatorname{argmax}_{w \in V} P(w | \mathbf{w}_{<t})$$

# Décodage glouton: choisit "all"



# Nous n'utilisons pas le décodage glouton

Parce que les tokens choisis sont (par définition) extrêmement prévisibles, le texte résultant est **générique et répétitif**

Le décodage glouton est si prévisible qu'il est **déterministe**.

On préfère plutôt un texte plus diversifié, comme celui généré par **échantillonnage**


# Échantillonnage aléatoire

**L'échantillonnage** à partir d'une distribution permet de choisir des points aléatoires en fonction de leur probabilité.

**L'échantillonnage à partir d'un LM** signifie choisir le token suivant à générer en fonction de sa probabilité.

**Échantillonnage aléatoire (multinomial)** : Nous sélectionnons au hasard un token à générer en fonction de sa probabilité définie par le LM, conditionné par nos choix précédents, le générons et itérons.

# Échantillonnage aléatoire



# Échantillonnage aléatoire

$i \leftarrow 1$

$w_i \sim p(w)$

**while**  $w_i \neq \text{EOS}$

$i \leftarrow i + 1$

$w_i \sim p(w_i \mid w_{<i})$

Hélas, l'échantillonnage aléatoire ne fonctionne pas très bien

Même si l'échantillonnage aléatoire génère surtout des mots plausibles et probables,

il existe beaucoup de mots étranges et peu probables dans la queue de la distribution

Pris individuellement ils sont peu probables, mais cumulés ils représentent une grande partie de la distribution

Ils sont donc choisis assez souvent pour produire des phrases bizarres

# Facteurs dans l'échantillonnage de mot: **qualité** et **diversité**

Mettre l'accent sur **les mots à forte probabilité** mots

+ **qualité**: Plus précis, cohérent, et factuel,

- **diversité**: plate, répétitif.

Mettre l'accent sur **les mots de mi-distribution**

+ **diversité**: plus créatif, plus divers,

- **qualité**: moins factuel, incohérent

# Échantillonnage top-k :

1. Choisir un nombre de mots  $k$
2. Pour chaque mot du vocabulaire  $V$ , utiliser le modèle de langage pour calculer la probabilité de ce mot donné le contexte  $p(w_t | w_{<t})$
3. Trier les mots par probabilité et ne garder que les  $k$  mots les plus probables.
4. ****Rénormaliser**** les scores des  $k$  mots pour obtenir une distribution de probabilité valide.
5. Échantillonner aléatoirement un mot parmi ces  $k$  most-probable mots according to its probability.

# Échantillonnage top-p (= nucleus sampling)

Holtzman et al., 2020

Problème du top- $k$ :  $k$  est fixe, il peut donc couvrir des quantités très différentes de masse de probabilité dans différentes situations

$$\sum_{w \in V(p)} P(w | \mathbf{w}_{<t}) \geq p.$$

# Échantillonnage top-p (= nucleus sampling)

Holtzman et al., 2020

Problème du top- $k$ :  $k$  est fixe, il peut donc couvrir des quantités très différentes de masse de probabilité dans différentes situations

Idée : au lieu de cela, conserver la part supérieure  $p$  de la masse de probabilité

$$\sum_{w \in V(p)} P(w | \mathbf{w}_{<t}) \geq p.$$

# Échantillonnage top-p (= nucleus sampling)

Holtzman et al., 2020

Problème du top- $k$ :  $k$  est fixe, il peut donc couvrir des quantités très différentes de masse de probabilité dans différentes situations

Idée : au lieu de cela, conserver la part supérieure  $p$  de la masse de probabilité

Étant donnée une distribution  $P(w_t | \mathbf{w}_{<t})$ , le vocabulaire top- $p$  Vocabulaire  $V(p)$  est le plus petit ensemble de mots tel que

$$\sum_{w \in V(p)} P(w | \mathbf{w}_{<t}) \geq p.$$

# Échantillonnage par température

## Remodeler la distribution de probabilité

- augmenter la probabilité des jetons très probables
- diminuer la probabilité des jetons peu probables

# Échantillonnage par température

Diviser le logit par un paramètre de température  $\tau$  avant de l'envoyer dans le softmax.



Au lieu de

$$\mathbf{y} = \text{softmax}(u)$$

Nous faisons

$$\mathbf{y} = \text{softmax}(u/\tau)$$

# Échantillonnage par température



# Échantillonnage par température

$$\mathbf{y} = \text{softmax}(u/\tau)$$

Comment cela fonctionne-t-il ?

# Échantillonnage par température

$$\mathbf{y} = \text{softmax}(\mathbf{u}/\tau)$$

Comment cela fonctionne-t-il ?

- Quand  $\tau$  est proche de 1, la distribution ne change pas beaucoup.

# Échantillonnage par température

$$\mathbf{y} = \text{softmax}(\mathbf{u}/\tau)$$

Comment cela fonctionne-t-il ?

- Quand  $\tau$  est proche de 1, la distribution ne change pas beaucoup.
- Plus  $\tau$  est faible, plus les scores envoyés au softmax sont grands


# Échantillonnage par température

$$\mathbf{y} = \text{softmax}(\mathbf{u}/\tau)$$

Comment cela fonctionne-t-il ?

- Quand  $\tau$  est proche de 1, la distribution ne change pas beaucoup.
- Plus  $\tau$  est faible, plus les scores envoyés au softmax sont grands
- Le softmax pousse les grandes valeurs vers 1 et les petites vers 0.

softmax output with temperature  $\tau$



# L'échantillonnage par température vient de la thermodynamique

- un système à haute température est flexible et peut explorer de nombreux états possibles,
- un système à plus basse température explorera plutôt un sous-ensemble d'états de plus basse énergie (meilleurs).

En **échantillonnage à basse température**, ( $\tau \leq 1$ ) nous

- augmentons la probabilité des mots les plus probables
- diminuons la probabilité des mots rares.

**Comment guider les générations d'un modèle?**

# Prompting : toutes les tâches vues comme de la génération texte-à-texte

**Prompt:** Une chaîne de texte qu'un utilisateur émet à un modèle de langage pour que le modèle fasse quelque chose d'utile par génération conditionnelle

**Prompt engineering:** Le processus de recherche de prompts efficaces pour une tâche.

# Prompting et apprentissage en contexte (ICL)

- Un prompt renvoie au contexte fourni au modèle de langage
- Divers composants d'un prompt, p. ex., instruction, description, etc.


## Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.



## Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.



# Prompts

Une question :

Qu'est-ce qu'un réseau Transformer ?

Peut-être structuré :

Q: Qu'est-ce qu'un réseau Transformer ? Un:

Ou une instruction :

Traduisez la phrase suivante en hindi : « Hachez finement l'ail ».

# Les prompts peuvent être très structurés

Human: Do you think that “input” has negative or positive sentiment?

Choices:

(P) Positive

(N) Negative

Assistant: I believe the best answer is: (

Les prompts peuvent contenir **des démonstrations** (= exemples)

The following are multiple choice questions about high school computer science.

Let  $x = 1$ . What is  $x \ll 3$  in Python 3?

(A) 1 (B) 3 (C) 8 (D) 16

Answer: C

Which is the largest asymptotically?

(A)  $O(1)$  (B)  $O(n)$  (C)  $O(n^2)$  (D)  $O(\log(n))$


Answer: C

What is the output of the statement `"a" + "ab"` in Python 3?

(A) Error (B) aab (C) ab (D) a ab

Answer:

**2 démonstrations**



# Prompting par chaîne de pensée (CoT)

## Standard Prompting

### Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

### Model Output

A: The answer is 27. ❌

## Chain-of-Thought Prompting

### Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls.  $5 + 6 = 11$ . The answer is 11.





Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

### Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had  $23 - 20 = 3$ . They bought 6 more apples, so they have  $3 + 6 = 9$ . The answer is 9. ✅

Idée principale : montrer à un modèle comment décomposer un problème en sous-problèmes plus simples

# Prompting par chaîne de pensée (CoT)



# Les prompts sont un signal d'apprentissage

C'est particulièrement clair avec des démonstrations

Mais c'est un autre type d'apprentissage que le pré-entraînement

- Le pré-entraînement fixe les poids du modèle via la descente de gradient
- Le prompting ne change que le contexte et les activations dans le réseau ; aucun paramètre ne change

On appelle cela **apprentissage en contexte**—un apprentissage qui améliore les performances du modèle sans mettre à jour les paramètres

Les LLM ont généralement un **system prompt**

**<system>**You are a helpful and knowledgeable assistant.  
Answer concisely and correctly.

Cela est automatiquement et silencieusement concaténé au  
prompt utilisateur

**<system>** You are a helpful and knowledgeable assistant.  
Answer concisely and correctly. **<user> What is the capital of  
France?**

Les prompts système peuvent être longs ; 1700 mots pour Claude Opus4

## Des extraits:

Claude should give concise responses to very simple questions, but provide thorough responses to complex and open-ended questions.

Claude is able to explain difficult concepts or ideas clearly. It can also illustrate its explanations with examples, thought experiments, or metaphors.

Claude does not provide information that could be used to make chemical or biological or nuclear weapons.

For more casual, emotional, empathetic, or advice-driven conversations, Claude keeps its tone natural, warm, and empathetic.

Claude cares about people's well-being and avoids encouraging or facilitating self-destructive behavior.

If Claude provides bullet points in its response, it should use markdown, and each bullet point should be at least 1-2 sentences long unless the human requests otherwise.

**TALN aujourd'hui : de nombreuses tâches peuvent être formulées comme une génération conditionnelle !**

Sentiment analysis: "I like Jackie Chan"

**TALN aujourd'hui : de nombreuses tâches peuvent être formulées comme une génération conditionnelle !**

Sentiment analysis: "I like Jackie Chan"

1. Nous donnons au modèle de langage cette chaîne :

Le sentiment de la phrase « J'aime Jackie Chan » est :

# TALN aujourd'hui : de nombreuses tâches peuvent être formulées comme une génération conditionnelle !

Sentiment analysis: "I like Jackie Chan"

1. Nous donnons au modèle de langage cette chaîne :

Le sentiment de la phrase « J'aime Jackie Chan » est :

2. Et on observe quel mot il prévoit ensuite

# TALN aujourd'hui : de nombreuses tâches peuvent être formulées comme une génération conditionnelle !

Sentiment analysis: "I like Jackie Chan"


1. Nous donnons au modèle de langage cette chaîne :

Le sentiment de la phrase « J'aime Jackie Chan » est :

2. Et on observe quel mot il prévoit ensuite

D'autres exemples ?

# Sentiment via génération conditionnelle



Quel mot a la probabilité la plus élevée ?

$P(\text{positive} | \text{The sentiment of the sentence "I like Jackie Chan" is:})$

$P(\text{negative} | \text{The sentiment of the sentence "I like Jackie Chan" is:})$

# Autres tâches comme génération conditionnelle : exemple Question-Réponse

QA: “Who wrote The Origin of Species”


1. Nous donnons au modèle de langage cette chaîne :

Q: Who wrote the book ‘‘The Origin of Species’’? A:

2. Et on voit quel mot vient ensuite :

$P(w|Q: \text{Who wrote the book ‘‘The Origin of Species’’? A:})$

# Autres tâches comme génération conditionnelle : exemple Question-Réponse



Maintenant, on itère :

$P(w|Q: \text{Who wrote the book 'The Origin of Species'? } A: \text{Charles})$

# Meilleurs LMs prédisent mieux le texte

Rappel de la règle de la chaîne :

$$\begin{aligned} P(w_{1:n}) &= P(w_1)P(w_2|w_1)P(w_3|w_{1:2}) \dots P(w_n|w_{1:n-1}) \\ &= \prod_{i=1}^n P(w_i|w_{<i}) \end{aligned}$$

Donc étant donné un texte  $w_{1:n}$  Nous pourrions simplement comparer la probabilité logarithmique de deux LM :

$$\log \text{likelihood}(w_{1:n}) = \log \prod_{i=1}^n P(w_i|w_{<i})$$

# Rappel : Perplexité

Comme pour d'autres modèles de langage, on utilise la perplexité pour mesurer à quel point le LLM prédit bien un texte inédit

La perplexité d'un modèle  $\theta$  sur un ensemble de tests est la probabilité inverse que  $\theta$  attribue à l'ensemble de tests, normalisée par la longueur de l'ensemble de test.

Pour un jeu de test de  $n$  tokens  $w_{1:n}$  la perplexité est :

$$\begin{aligned}\text{Perplexity}_{\theta}(w_{1:n}) &= P_{\theta}(w_{1:n})^{-\frac{1}{n}} \\ &= \sqrt[n]{\frac{1}{P_{\theta}(w_{1:n})}}\end{aligned}$$

# Pourquoi la perplexité plutôt que la probabilité brute du jeu de test ?

- La probabilité dépend de la taille du jeu de test
  - La probabilité diminue à mesure que le texte s'allonge
  - Mieux : une métrique qui est **par mot**, normalisée par la longueur
- **Perplexité** est l'inverse de la probabilité du jeu de test, normalisée par le nombre de mots
  - (L'inverse vient de la définition originale de la perplexité via le taux d'entropie croisée en théorie de l'information)
  - Probabilité entre  $[0,1]$ , perplexité entre  $[1,\infty]$

# Perplexité

- Plus la probabilité de la séquence de mots est élevée, plus la perplexité est faible.
- Ainsi, plus la perplexité d'un modèle sur les données est faible, meilleur est le modèle.
- **Minimiser la perplexité revient à maximiser la probabilité**
- Aussi : la perplexité est sensible à la longueur/à la tokenisation ; mieux vaut comparer des LMs qui utilisent le même tokenizer.

Beaucoup d'autres facteurs que nous évaluons, comme :

### **Taille**

Les grands modèles exigent beaucoup de GPUs et du temps d'entraînement, ainsi que de la mémoire pour le stockage

### **Consommation d'énergie**

On peut mesurer en kWh ou en kilogrammes de CO₂ émis

### **Équité**

Des benchmark mesurent les stéréotypes de genre et raciaux, ou la baisse de performance pour des langues de/à propos de certains groupes.

**[Pause de 15 minutes]**

# *Chatbots May 'Hallucinate' More Often Than Many Realize*

## *What Can You Do When A.I. Lies About You?*

People have little protection or recourse when the technology creates and spreads falsehoods about them.

## **Air Canada loses court case after its chatbot hallucinated fake policies to a customer**

The airline argued that the chatbot itself was liable. The court disagreed.

# Hallucination

*Chatbots May 'Hallucinate'  
More Often Than Many Realize*

## *What Can You Do When A.I. Lies About You?*

People have little protection or recourse when the technology creates and spreads falsehoods about them.

## **Air Canada loses court case after its chatbot hallucinated fake policies to a customer**

The airline argued that the chatbot itself was liable. The court disagreed.



## Authors Sue OpenAI Claiming Mass Copyright Infringement of Hundreds of Thousands of Novels

### *The Times Sues OpenAI and Microsoft Over A.I. Use of Copyrighted Work*

Millions of articles from The New York Times were used to train chatbots that now compete with it, the lawsuit said.



# Droit d'auteur



**Authors Sue OpenAI Claiming Mass Copyright  
Infringement of Hundreds of Thousands of Novels**

## ***The Times Sues OpenAI and Microsoft Over A.I. Use of Copyrighted Work***

Millions of articles from The New York Times were used to train chatbots that now compete with it, the lawsuit said.



# How Strangers Got My Email Address From ChatGPT's Model

**Vie privée**

**How Strangers Got My Email  
Address From ChatGPT's Model**

# **The New AI-Powered Bing Is Threatening Users.**

## **Cleaning Up ChatGPT Takes Heavy Toll on Human Workers**

Contractors in Kenya say they were traumatized by effort to screen out descriptions of violence and sexual abuse during run-up to OpenAI's hit chatbot

# Toxicité et abus

**The New AI-Powered Bing Is Threatening Users.**

## **Cleaning Up ChatGPT Takes Heavy Toll on Human Workers**

Contractors in Kenya say they were traumatized by effort to screen out descriptions of violence and sexual abuse during run-up to OpenAI's hit chatbot

**Chatbots are generating false and misleading information about U.S. elections**

# **Désinformation**


**Chatbots are generating false and misleading information about U.S. elections**

## Et bien d'autres

- Sécurité (suggestion d'actions dangereuses)
- Fraude (usurpation d'identité, deepfakes)
- Dépendance émotionnelle (préjudice psychologique)
- Biais (amplification de biais nuisibles)

# Frankenstein de Mary Shelley

Centré sur le problème de créer des agents artificiels sans considérer les enjeux éthiques et humanistes.



# **Mais où se situent la responsabilité et l'imputabilité?**

Créateurs ? Modèles ? Utilisateurs ? Gouvernements ?

**Quelle est alors votre  
responsabilité et votre  
imputabilité?**

# ***Who Pays When A.I. Is Wrong?***

New court cases seek to define content created by artificial intelligence as defamatory — a novel concept that has captivated some legal experts.

## ***Social Media Giants Face Landmark Legal Tests on Child Safety***

Starting this week, a series of trials will test a new legal strategy claiming that Meta, TikTok, Snap and YouTube caused personal injury through addictive products.

# Danger was flagged, but not reported: What the Tumbler Ridge tragedy reveals about Canada's AI governance vacuum

Published: February 24, 2026 2.19pm EST

Flowers are placed in a barricade pylon on a road leading to Tumbler Ridge Secondary School in Tumbler Ridge, B.C., where a mass shooting took place on Feb. 10. The shooter's ChatGPT account was flagged by an automated program months earlier for interactions involving scenarios of gun violence. THE CANADIAN PRESS/Christinne Muschi



Eight months before the Tumbler Ridge mass shooting, OpenAI knew something was wrong. The company's automated review system had flagged Jesse Van Rootselaar's ChatGPT account for interactions involving scenarios of gun violence. Roughly a dozen employees were aware. Some advocated contacting police. Instead, OpenAI banned the account, but didn't refer it to law enforcement because it didn't meet the "threshold required" at the time.

## Author



**Jean-Christophe Bélisle-Pipon**

Assistant Professor in Health Ethics, Simon Fraser University

## Disclosure statement

Jean-Christophe Bélisle-Pipon receives funding from Michael Smith Health Research BC Scholar Award and the US National

