

Modèles Encodeur-Decodeur et la génération texte-à-texte

TALN Semaine 10


Merci à Dan Jurafsky et Marius Mosbach pour certaines des diapos d'aujourd'hui

Plan pour aujourd'hui

1. **Présentation de la modélisation séquence-à-séquence (seq-to-seq) avec des RNN encodeur-décodeur**
2. **Transformers encodeur-décodeur**
3. **Traduction automatique**
4. **T5 : texte-à-texte partout**
5. ***Exercice de groupe : étude de cas***

Unités neuronales récurrentes simples (SRN ou Elman Net)

Rappel semaine 6



La couche cachée a une récurrence dans ses valeurs d'entrées
La valeur d'activation h_t depend de x_t et aussi de h_{t-1} !

Architectures RNN


Rappel semaine 6

Nous verrons trois types d'architectures RNN qui peuvent être utilisées pour différentes tâches :


1. RNN pour la modélisation du langage

2. RNN pour la classification


3. RNN pour l'étiquetage séquentiel



c) language modeling



b) sequence classification




a) sequence labeling


Deux types de tâches de prédiction de séquence

Rappel semaine 6

1. **Étiquetage séquentiel** : Lorsque la longueur de la séquence de sortie correspond à celle de l'entrée
2. **modèle seq-à-seq ou encodeur-decodeur** : Lorsque les séquences de sortie et d'entrée sont de longueur différente
(Semaine 10 du cours)



a) sequence labeling




d) encoder-decoder

RNN pour l'étiquetage séquentiel

Rappel semaine 6

Attribuer une étiquette à chaque élément d'une séquence (ex. Étiquetage morphosyntaxique (POS tagging)):

- La principale différence avec l'architecture LM et l'architecture de classification est que la dimension de sortie est sur le nombre d'étiquettes (pas le vocabulaire), et qu'il y a une prédiction de sortie à chaque état de temps (pas seulement le dernier).




RNN pour les tâches de séquence à séquence

Un exemple d'une telle tâche est la traduction :


‘Have you tasted *loroco* before?’

‘Avez-vous déjà goûté au *loroco*?’



3 composants d'un encodeur-décodeur

1. Un encodeur qui accepte une séquence d'entrée, $\mathbf{x}_{1:n}$, et génère une séquence correspondante de représentations contextualisées cachées, $\mathbf{h}_{1:n}$.
2. Un vecteur de contexte, $\mathbf{c}$, qui est une fonction de $\mathbf{h}_{1:n}$, et transmet l'essence de l'entrée au décodeur.
3. Un décodeur, qui accepte $\mathbf{c}$ comme entrée et génère une séquence de longueur arbitraire d'états cachés $\mathbf{h}_{1:m}$, à partir de laquelle une séquence correspondante d'états de sortie $\mathbf{y}_{1:m}$, peut être obtenue



Encodeur-décodeur pour la traduction

Modélisation du langage régulier

$$p(y) = p(y_1)p(y_2|y_1)p(y_3|y_1, y_2) \dots p(y_m|y_1, \dots, y_{m-1})$$

Notation de séquence conditionnée


Que x soit le texte source plus un token séparé $\langle s \rangle$ et y la cible

x = The green witch arrive $\langle s \rangle$

y = *llego' la bruja verde*

$$p(y|x) = p(y_1|x)p(y_2|y_1, x)p(y_3|y_1, y_2, x) \dots p(y_m|y_1, \dots, y_{m-1}, x)$$


Encodeur-décodeur simplifié



Encodeur-décodeur montrant le contexte

Où chaque état caché du décodeur est conditionné non seulement sur l'entrée et l'état caché précédent, mais aussi sur le contexte.

$$\mathbf{h}_t^d = g(\hat{y}_{t-1}, \mathbf{h}_{t-1}^d, \mathbf{c})$$



Équations encodeur-décodeur

$$\begin{aligned}\mathbf{c} &= \mathbf{h}_n^e \\ \mathbf{h}_0^d &= \mathbf{c} \\ \mathbf{h}_t^d &= g(\hat{\mathbf{y}}_{t-1}, \mathbf{h}_{t-1}^d, \mathbf{c}) \\ \hat{\mathbf{y}}_t &= \text{softmax}(\mathbf{h}_t^d)\end{aligned}$$


g est un stand-in pour un certain type de RNN

$\hat{\mathbf{y}}_{t-1}$ est l'embedding de la sortie échantillonnée du softmax précédent


$\hat{\mathbf{y}}_t$ est le vecteur des probabilités sur le vocabulaire, représentant la probabilité que chaque mot se produise au moment t .

Pour générer du texte, nous échantillonnons à partir de cette distribution $\hat{\mathbf{y}}_t$.

Entraîner un encodeur-décodeur avec le teacher-forcing




RNN enc-dec et l'attention simplifié



RNN enc-dec et l'attention simplifié


You may have noticed a problem...



RNN enc-dec et l'attention simplifié

You may have noticed a problem...

c le vecteur de contexte est tiré de l'état final de l'encodeur, créant un bottleneck, où **c** doit encoder des informations utiles sur la phrase de référence pour tous les mots de la phrase cible.




RNN enc-dec et l'attention simplifié

You may have noticed a problem...

c le vecteur de contexte est tiré de l'état final de l'encodeur, créant un bottleneck, où **c** doit encoder des informations utiles sur la phrase de référence pour tous les mots de la phrase cible.


Solution: *attention!* (...où tout a commencé)



RNN enc-dec et l'attention simplifié

Chaque étape i du décodeur obtient maintenant comme entrée l'embedding $\mathbf{y}_{i-1}$ pour le mot précédent et le vecteur $\mathbf{c}_i$, qui "s'attends/s'attarde à" l'information utile de tous les états cachés de l'encodeur $\mathbf{h}^e$


$$\mathbf{c}_i = \sum_j \alpha_{ij} \mathbf{h}_j^e$$



Transformers Encodeur-décodeur (... “attention is all you need”)

- Maintenant, nous verrons une classe différente de modèles basés sur Transformer qui ont été / sont largement utilisés


Trois architectures de grands modèles de langage



Decodeurs


GPT, Claude,
Llama

Mixtral



Encodeurs


BERT family,
HuBERT



Encodeur-decodeurs

Flan-T5, Whisper

Encodeur-Decodeurs



- Formé à correspondre d'une séquence à une autre
- Très populaire pour :
 - Traduction automatique (d'une langue à l'autre)
 - Reconnaissance vocale (de l'acoustique aux mots)

Le papier qui a tout déclenché

Rappel semaine 7

Transformateur : un type spécifique d'architecture de réseau, comme un réseau feedforward plus sophistiqué, mais basé sur l'attention

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com


Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Lukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com


Le modèle transformers original étaient un enc-dec

- **Encodeur**
 - Self-attention bidirectionnel
- **Decodeur**
 - self-attention causal
- Comment l'encodeur et le décodeur « communiquent-ils » entre eux ?
 - **Cross-attention**




Cross-attention dans le décodeur

- Le bloc transformer du décodeur a deux sous-couches de self-attention au lieu d'une!
- **Self-attention** avec $\mathbf{Q} = \mathbf{XW}^Q$, $\mathbf{K} = \mathbf{XW}^K$, et $\mathbf{V} = \mathbf{XW}^V$
- **Cross-attention** avec $\mathbf{Q} = \mathbf{XW}^Q$, $\mathbf{K} = \mathbf{X}_{\text{enc}}^L \mathbf{W}^K$, et $\mathbf{V} = \mathbf{X}_{\text{enc}}^L \mathbf{W}^V$
- Où les keys et les values sont basées sur les représentations de la dernière couche de l'encodeur !



L'architecture du modèle enc-dec



Traduction automatique via les modèles enc-dec

TextBilderDokumenteWebsites

Sprache erkennenFriesischDeutschEnglisch

HEC Montréal (French: Hautes études commerciales de Montréal; English: High Commercial Studies of Montreal) is a bilingual public business school located in Montreal, Quebec, Canada. Founded in 1907, HEC Montréal is the graduate business school of the Université de Montréal and is the first established school of management in Canada.[2][3]

HEC Montréal offers undergraduate, graduate, and post-graduate programs, including Bachelor of Business Administration (BBA), Master of Science in Administration (MSc), Master of Management (MM), Master of Business Administration (MBA), and PhD in Administration, in addition to a joint Executive MBA program with McGill University.



675 / 5.000

↔Französisch (Kanada)FriesischEnglisch

HEC Montréal (en français : Hautes études commerciales de Montréal ; en anglais : High Commercial Studies of Montréal) est une école de commerce publique bilingue située à Montréal, Québec, Canada. Fondée en 1907, HEC Montréal est l'école supérieure de gestion de l'Université de Montréal et la première école de gestion établie au Canada.[2][3]

HEC Montréal offre des programmes de premier, deuxième et troisième cycles, dont un baccalauréat en administration des affaires (B.A.A.), une maîtrise en sciences de l'administration (M.Sc.), une maîtrise en gestion (M.M.), une maîtrise en administration des affaires (M.B.A.) et un doctorat en administration, en plus d'un programme conjoint de MBA pour cadres avec l'Université McGill.





Feedback geben

Diversité linguistique

- Il y a ~ 7000 langues dans le monde
- Certains aspects du langage humain semblent être *universels*
 - Tiennent la vérité pour chaque langue
 - *Statistiquement universel* : vrai pour presque toutes les langues
- Par exemple, chaque langue semble avoir des noms et des verbes
- Pourtant, **les langues diffèrent aussi à bien des égards**
- Cela fait de la traduction automatique un problème intéressant et difficile en TALN

Typologie

- Parfois, les différences entre les langues sont systématiques
- La **typologie** étudie ces similitudes et différences interlinguistiques systématiques
- Exemple :
 - **Ordre des mots**
 - SVO
 - SOV
 - VSO
- Connaissez-vous des exemples de langues pour chaque ?



Typologie

- Parfois, les différences entre les langues sont systématiques
- La **typologie** étudie ces similitudes et différences interlinguistiques systématiques
- Exemple :
 - **Ordre des mots**
 - SVO : français, anglais
 - SOV : japonais
 - VSO : arabe
- Connaissez-vous des exemples de langues pour chaque ?



Typologie

- Parfois, les différences entre les langues sont systématiques
- La **typologie** étudie ces similitudes et différences interlinguistiques systématiques
- Exemple :
 - **Ordre des mots**
 - SVO : français, anglais
 - SOV : japonais
 - VSO : arabe
- Connaissez-vous des exemples de langues pour chaque ?



English: *He wrote a letter to a friend*
Japanese: *tomodachi ni tegami-o kaita*
 friend to letter wrote
Arabic: *katabt risāla li šadq*
 wrote letter to friend

Divergences lexicales

- Lors de la traduction, nous devons également faire le liens entre les mots d'une langue à l'autre.
- Mais le mot approprié peut varier en fonction du contexte
- Exemple :
 - *wall* (anglais)
 - *mauer* or *wand* (allemand)
 - *wand* est typiquement utilisé à l'intérieur seulement




The Berlin Wall (Berliner Mauer)

Berliner Wand semblerait vraiment étrange pour n'importe quel Allemand

Divergences lexicales

- Comment traduiriez-vous les mots anglais *leg, paw, ou foot*?



- Il existe également des lacunes lexicales : aucun mot ou phrase ne peut exprimer le sens exact dans une autre langue, ex. *dépaysement* - n'a pas une seule traduction en anglais

Traduction automatique avec les modèles enc-dec

- Souvent, les systèmes de traduction supposent que les phrases sont indépendantes, c'est-à-dire que nous travaillons avec un corpus de phrases alignées dans deux (ou plusieurs) langues
- Quel est l'objectif d'apprentissage?
 - $P(y_1, \dots, y_m \mid x_1, \dots, x_n)$
 - Paramétré par un réseau neuronal enc-dec

$$\begin{aligned}\mathbf{h} &= \text{encoder}(x) \\ y_{t+1} &= \text{decoder}(\mathbf{h}, y_1, \dots, y_t) \quad \forall t \in [1, \dots, m]\end{aligned}$$

Données d'entraînement

E1: "Good morning," said the little prince.

F1: -Bonjour, dit le petit prince.

E2: "Good morning," said the merchant.

F2: -Bonjour, dit le marchand de pilules perfectionnées qui apaisent la soif.

E3: This was a merchant who sold pills that had been perfected to quench thirst.

F3: On en avale une par semaine et l'on n'éprouve plus le besoin de boire.

E4: You just swallow one pill a week and you won't feel the need for anything to drink.

F4: -C'est une grosse économie de temps, dit le marchand.

E5: "They save a huge amount of time," said the merchant.

F5: Les experts ont fait des calculs.

E6: "Fifty-three minutes a week."

F6: On épargne cinquante-trois minutes par semaine.

E7: "If I had fifty-three minutes to spend?" said the little prince to himself.


F7: "Moi, se dit le petit prince, si j'avais cinquante-trois minutes à dépenser, je marcherais tout doucement vers une fontaine..."

E8: "I would take a stroll to a spring of fresh water"

Décodage via beam-search


- Nous avons vu quelques méthodes de décodage pour les tâches de génération de texte, telles que le décodage greedy où le mot a toujours choisi avec la probabilité la plus élevée
 - $\hat{w} = \operatorname{argmax}_{w \in \mathcal{V}} P(w \mid \mathbf{w}_{<t})$
- Mais bien greedy soit +haute qualité, il n'est pas nécessairement optimale, en particulier pour la traduction.
- Nous avons également vu l'échantillonnage k-top et p-top qui ont +diversité pour la génération, mais lorsque nous traduisons, nous ne voulons pas nécessairement de diversité.
- **Beam search** est une méthode alternative pour le décodage
- considère plusieurs alternatives (hypothèses) en parallèle pour trouver l'optimale- c'est le meilleur choix pour des tâches comme la traduction automatique

Décodage via beam-search




Décodage via beam-search

- Dans le problème à droite, la séquence avec la plus grande **probabilité conjointe** est "ok ok EOS"




Décodage via beam-search

- Dans le problème à droite, la séquence avec la plus grande **probabilité conjointe** est "ok ok EOS"
- Il s'agit de beam search avec $k=3$ beam




Décodage via beam-search

- Dans le problème à droite, la séquence avec la plus grande **probabilité conjointe** est "ok ok EOS"
- Il s'agit de beam search avec $k=3$ beam




Décodage via beam-search

- Dans le problème à droite, la séquence avec la plus grande **probabilité conjointe** est "ok ok EOS"
- Il s'agit de beam search avec $k=3$ beam
- Le décodage greedy est incapable de décoder cette séquence




Décodage via beam-search

- Dans le problème à droite, la séquence avec la plus grande **probabilité conjointe** est "ok ok EOS"
- Il s'agit de beam search avec $k=3$ beam
- Le décodage greedy est incapable de décoder cette séquence
 - Pouvez-vous comprendre pourquoi ?




Décodage via beam-search

- Dans le problème à droite, la séquence avec la plus grande **probabilité conjointe** est "ok ok EOS"
- Il s'agit de beam search avec $k=3$ beam
- Le décodage greedy est incapable de décoder cette séquence
 - Pouvez-vous comprendre pourquoi ?
 - Qu'en est-il de beam search?




Décodage via beam-search

- À chaque étape, considérez k continuations possibles (largeur du beam)



Notation avec Beam search

- Nous maintenons la probabilité log à chaque étape et les additionnons le long des chemins que nous développons



Évaluation des systèmes de traduction

- Qu'est-ce qui fait une bonne traduction ?
 - **Adequate**
 - **Semble naturelle**
 - L'étalon d'or ~> **Évaluation humaine**
 - Problème : peut être cher et lent
- Nous voulons une bonne **évaluation automatique**
 - Potentiellement moins précis, mais peut toujours fournir un bon signal pour comparer deux systèmes

Évaluation des systèmes de traduction

- **Character F-score (chrF)**

- chrP: Pourcentage de caractères 1-grammes, 2-grammes, ..., n-grammes dans l'hypothèse qui se produisent également dans la cible (moyenne)
- chrR: Pourcentage de caractères 1-gramme, 2-grammes, ..., n-grammes dans la cible qui se produisent également dans l'hypothèse (moyenne)
- Calculez un F-score en combinant les deux

$$\text{chrF}\beta = (1 + \beta^2) \frac{\text{chrP} \cdot \text{chrR}}{\beta^2 \cdot \text{chrP} + \text{chrR}}$$

$$\text{chrF2} = \frac{5 \cdot \text{chrP} \cdot \text{chrR}}{4 \cdot \text{chrP} + \text{chrR}}$$

Évaluation des systèmes de traduction

- **BLEU score**
 - Purement basé sur la précision
 - Précision des mots N-gram
 - Considérez un corpus $\mathcal{C}$ avec une seule phrase, i.e., $\mathcal{C} = \{s\}$ (*Sentence BLEU*)
 - Uni-gram precision: Pourcentage d'unigrams dans la traduction (hypothèse) qui se produit également dans le corpus.

Évaluation des systèmes de traduction

- ***Sentence BLEU score***

- Calculez la précision des n-grams pour les uni-, bi-, tri- et 4-grams et prenez la moyenne géométrique

- Les inconvénients:

- Basé sur des mots, ce qui rend difficile la comparaison des systèmes avec différentes tokenisations
- Ne fonctionne pas bien pour les langues avec une morphologie complexe

- Tout le monde en TALN sait que BLEU n'est pas génial, mais nous l'utilisons toujours...

Méthodes à base d'embeddings

Méthodes à base d'embeddings

chrF et BLEU tous deux nécessitent une traduction cible, que faisons-nous quand nous n'en avons pas ?

Méthodes à base d'embeddings

chrF et BLEU tous deux nécessitent une traduction cible, que faisons-nous quand nous n'en avons pas ?


-> Similitude des embeddings!

Méthodes à base d'embeddings

chrF et BLEU tous deux nécessitent une traduction cible, que faisons-nous quand nous n'en avons pas ?

-> Similitude des embeddings!


- Étape 1 : Compare les embeddings de tous les tokens des phrases de référence et traduites



Méthodes à base d'embeddings

- Étape 2: Prenez les paires de mots avec la similarité maximales et obtenez la moyenne sur (i) les mots de référence et (ii) les mots candidats/traduction

$$R_{\text{BERT}} = \frac{1}{|x|} \sum_{x_i \in x} \max_{\tilde{x}_j \in \tilde{x}} x_i \cdot \tilde{x}_j \quad P_{\text{BERT}} = \frac{1}{|\tilde{x}|} \sum_{\tilde{x}_j \in \tilde{x}} \max_{x_i \in x} x_i \cdot \tilde{x}_j$$




Biais et problèmes éthiques

- Les biais sont souvent amplifiés dans les systèmes de traduction... parce que nous essayons toujours de trouver la valeur de sortie avec la probabilité la plus élevée.
- Que se passe-t-il lorsque nous traduisons une langue avec un pronom neutre (hongrois) ou qui laisse tomber des pronoms (espagnol) dans une langue avec des pronoms M/F (anglais ou français) ?

Hungarian (gender neutral) source	English MT output
ő egy ápoló	she is a nurse
ő egy tudós	he is a scientist
ő egy mérnök	he is an engineer
ő egy pék	he is a baker
ő egy tanár	she is a teacher
ő egy vesküvőszervező	she is a wedding organizer
ő egy vezérigazgató	he is a CEO

(Prates et al. 2019)

T5: seq-à-seq partout





Il y a quelques images célèbres dans notre domaine, c'est l'une d'entre elles :)

T5: seq-à-seq partout

- Format général de **texte-à-texte**
- Traduction automatique
 - Traduisez ce texte en français : Montréal est génial.
Montréal est génial
- Résumé
 - Résumez cet article de presse : [Certains articles]
[Résumé de l'article]
- À quelles autres tâches pouvez-vous penser ?
- Pouvez-vous penser à une tâche TALN qui **ne peut pas** être formatée comme texte-à-texte ?


Quel est le meilleur modèle pour l'apprentissage texte à texte ?

- **Structure du modèle**
- Quelle attention devrions-nous utiliser ?
 - Bidirectionnel
 - Causal
 - Un mélange des deux
- **Architecture du modèle**
 - Encodeur-décodeur
 - Décodeur uniquement
 - Un mélange des deux



Quel est le meilleur modèle pour l'apprentissage texte à texte ?


- **Objectif d'entraînement**
- Quelle est la meilleure façon d'encoder des informations utiles et de décoder à partir d'une séquence ?



Objective	Inputs	Targets
Prefix language modeling	Thank you for inviting	me to your party last week .
BERT-style Devlin et al. (2018)	Thank you <M> <M> me to your party apple week .	(original text)
Deshuffling	party me for your to . last fun you inviting week Thank	(original text)
MASS-style Song et al. (2019)	Thank you <M> <M> me to your party <M> week .	(original text)
I.i.d. noise, replace spans	Thank you <X> me to your party <Y> week .	<X> for inviting <Y> last <Z>
I.i.d. noise, drop tokens	Thank you me to your party week .	for inviting last
Random spans	Thank you <X> to <Y> week .	<X> for inviting me <Y> your party last <Z>

Quel est le meilleur modèle pour l'apprentissage texte à texte ?

- Essayez simplement toutes les combinaisons possibles



Quel est le meilleur modèle pour l'apprentissage texte à texte ?

Objective	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
BERT-style (Devlin et al., 2018)	82.96	19.17	80.65	69.85	26.78	40.03	27.41
MASS-style (Song et al., 2019)	82.32	19.16	80.10	69.28	26.79	39.89	27.55
★ Replace corrupted spans	83.28	19.24	80.88	71.36	26.98	39.82	27.65
Drop corrupted tokens	84.44	19.31	80.52	68.67	27.07	39.76	27.82

Corruption rate	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
10%	82.82	19.00	80.38	69.55	26.87	39.28	27.44
★ 15%	83.28	19.24	80.88	71.36	26.98	39.82	27.65
25%	83.00	19.54	80.96	70.48	27.04	39.83	27.47
50%	81.27	19.32	79.80	70.33	27.01	39.90	27.49

Span length	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
★ Baseline (i.i.d.)	83.28	19.24	80.88	71.36	26.98	39.82	27.65
2	83.54	19.39	82.09	72.20	26.76	39.99	27.63
3	83.49	19.62	81.84	72.53	26.86	39.65	27.62
5	83.40	19.24	82.05	72.23	26.88	39.40	27.53
10	82.85	19.33	81.84	70.44	26.79	39.49	27.69

- Chacun à un impact dans une certaine mesure

Quel est le meilleur modèle pour l'apprentissage texte à texte ?

Architecture	Objective	Params	Cost	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
★ Encoder-decoder	Denoising	$2P$	M	83.28	19.24	80.88	71.36	26.98	39.82	27.65
Enc-dec, shared	Denoising	P	M	82.81	18.78	80.63	70.73	26.72	39.03	27.46
Enc-dec, 6 layers	Denoising	P	$M/2$	80.88	18.97	77.59	68.42	26.38	38.40	26.95
Language model	Denoising	P	M	74.70	17.93	61.14	55.02	25.09	35.28	25.86
Prefix LM	Denoising	P	M	81.82	18.61	78.94	68.11	26.43	37.98	27.39
Encoder-decoder	LM	$2P$	M	79.56	18.59	76.02	64.29	26.27	39.17	26.86
Enc-dec, shared	LM	P	M	79.60	18.13	76.35	63.50	26.62	39.17	27.05
Enc-dec, 6 layers	LM	P	$M/2$	78.67	18.26	75.32	64.06	26.13	38.42	26.89
Language model	LM	P	M	73.78	17.54	53.81	56.51	25.23	34.31	25.38
Prefix LM	LM	P	M	79.68	17.84	76.87	64.86	26.28	37.51	26.76

- Certaines combinaisons sont meilleures que d'autres
- Denoising (par ex. MLM) semble être presque toujours meilleur que la prédiction du prochain token (LM) avec l'architecture dec-encs

(Raffel et al. 2020)

Quel est le meilleur modèle pour l'apprentissage texte à texte ?

- Il manque un ingrédient important
- Pouvez-vous deviner lequel ?

Quel est le meilleur modèle pour l'apprentissage texte à texte ?

- Il manque un ingrédient important
- Pouvez-vous deviner lequel ?

Données!




Quel est le meilleur modèle pour l'apprentissage texte à texte ?

- Données 
- C4: Colossal Clean Crawled Corpus

Data set	Size	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
★ C4	745GB	83.28	19.24	80.88	71.36	26.98	39.82	27.65
C4, unfiltered	6.1TB	81.46	19.14	78.78	68.04	26.55	39.34	27.21
RealNews-like	35GB	83.83	19.23	80.39	72.38	26.75	39.90	27.48
WebText-like	17GB	84.03	19.31	81.42	71.40	26.80	39.74	27.59
Wikipedia	16GB	81.85	19.31	81.29	68.01	26.94	39.69	27.67
Wikipedia + TBC	20GB	83.65	19.28	82.08	73.24	26.77	39.63	27.57

Number of tokens	Repeats	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
★ Full data set	0	83.28	19.24	80.88	71.36	26.98	39.82	27.65
2^{29}	64	82.87	19.19	80.97	72.03	26.83	39.74	27.63
2^{27}	256	82.62	19.20	79.78	69.97	27.02	39.71	27.33
2^{25}	1,024	79.55	18.57	76.27	64.76	26.38	39.56	26.80
2^{23}	4,096	76.34	18.33	70.92	59.29	26.37	38.84	25.81

Performance par taille




Model	GLUE Average	CoLA Matthew's	SST-2 Accuracy	MRPC F1	MRPC Accuracy	STS-B Pearson	STS-B Spearman
Previous best	89.4 ^a	69.2 ^b	97.1 ^a	93.6^b	91.5^b	92.7 ^b	92.3 ^b
T5-Small	77.4	41.0	91.8	89.7	86.6	85.6	85.0
T5-Base	82.7	51.1	95.2	90.7	87.5	89.4	88.6
T5-Large	86.4	61.2	96.3	92.4	89.9	89.9	89.2
T5-3B	88.5	67.1	97.4	92.5	90.0	90.6	89.8
T5-11B	90.3	71.6	97.5	92.8	90.4	93.1	92.8

Model	QQP F1	QQP Accuracy	MNLI-m Accuracy	MNLI-mm Accuracy	QNLI Accuracy	RTE Accuracy	WNLI Accuracy
Previous best	74.8 ^c	90.7^b	91.3 ^a	91.0 ^a	99.2^a	89.2 ^a	91.8 ^a
T5-Small	70.0	88.0	82.4	82.3	90.3	69.9	69.2
T5-Base	72.6	89.4	87.1	86.2	93.7	80.1	78.8
T5-Large	73.9	89.9	89.9	89.6	94.8	87.2	85.6
T5-3B	74.4	89.7	91.4	91.2	96.3	91.1	89.7
T5-11B	75.1	90.6	92.2	91.9	96.9	92.8	94.5

- Vraiment bien dans tous les domaines. Nouveau SOTA sur plusieurs tâches pour les petits LM.

T5: seq-à-seq partout



- Recherche exhaustive sur l'espace des modèles possibles seq-à-seq
- Modèle enc-dec open source pré-entraîné très fort

T5: seq-à-seq partout

"translate English to German: That is good."

**Mais les LLM peuvent faire tout cela !
Quand pourrions-nous donner la priorité à l'un
plutôt qu'à l'autre ?**

"summarize: state authorities
dispatched emergency crews tuesday to
survey the damage after an onslaught
of severe weather in mississippi..."

six people hospitalized after
a storm in attala county."

- Recherche exhaustive sur l'espace des modèles possibles seq-à-seq
- Modèle enc-dec open source pré-entraîné très fort

Prompting : toutes les tâches vues comme de la génération texte-à-texte

Rappel semaine 8

Prompt: Une chaîne de texte qu'un utilisateur émet à un modèle de langage pour que le modèle fasse quelque chose d'utile par génération conditionnelle

Prompt engineering: Le processus de recherche de prompts efficaces pour une tâche.

Prompting et apprentissage en contexte (ICL)

Rappel semaine 8

- Un prompt renvoie au contexte fourni au modèle de langage
- Divers composants d'un prompt, p. ex., instruction, description, etc.


Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.



Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.



[Pause - 15 minutes]

Étude de cas : Un compagnon IA d'assurance

Le cas de la semaine dernière

Votre client est une compagnie d'assurance. L'évaluation équitable des réclamations demande beaucoup de formation et de connaissances accumulées, mais l'entreprise fait face à beaucoup de roulement d'employés (l'assurance n'est pas toujours le plus heureux des emplois !) Ce qui signifie que ces connaissances continuent de se perdre et que la formation des nouveaux employés est coûteuse. Comme solution pour réduire le temps de transfert de connaissances, vous proposez de créer un assistant d'IA qui aidera les agents à réclamation avec leur évaluation initiale. Son rôle sera d'identifier (1) le type de réclamation le plus probable et (2) les sections du contrat d'assurance du client qui font référence à ce type de réclamation. Il devrait ensuite (3) générer une évaluation initiale de l'admissibilité de la réclamation et des résolutions possibles. Vous avez accès aux documents suivants : (i) les réclamations écrites des clients et leurs contrat d'assurance complets (déjà mappés), (ii) l'ensemble de toutes les réclamations résolues et leurs résolutions des 5 dernières années, (iii) une liste des catégories de réclamations.

Étude de cas : Un compagnon IA d'assurance

Le cas de la semaine dernière

- Esquissez la structure procédurale de votre assistant d'IA, en décrivant chaque étape et les technologies de TALN qui seront nécessaires. Si plusieurs sont possibles (par exemple, différents LM pourraient être utilisés), mettez en évidence lequel choisiriez-vous et pourquoi ?
- Identifiez les limites de vos solutions et où elles peuvent introduire des erreurs. Quel peut être votre niveau de responsabilité et d'imputabilité pour ces erreurs ?
- **Considérez les défis possibles que votre solution peut présenter en matière de souveraineté des données, de confidentialité des clients et de coûts de calcul pour l'entreprise.**

The Clarifying Lawful Overseas Use of Data (CLOUD) Act, passed in 2018, allows U.S. law enforcement to compel U.S.-based technology companies to disclose electronic data, such as emails or files, regardless of whether the data is stored in the United States or on foreign servers. It focuses on control rather than data location. [Wikipedia +3](#)

Key Aspects of the CLOUD Act

- **Scope:** Applies to any service provider subject to U.S. jurisdiction, covering major cloud providers like Google, Amazon, Microsoft, and Apple.
- **Cross-Border Access:** Eliminates the need to rely solely on slow, traditional Mutual Legal Assistance Treaties (MLAT) for accessing data stored abroad.
- **Data Sovereignty Conflicts:** It can force companies to turn over data even if doing so violates local privacy laws (e.g., GDPR in the EU or Canadian law).

[News](#) > [World](#) > [Europe](#)

European governments ditch US tech services over security fears

European governments are moving away from US tech giants, opting for domestic or open-source alternatives

France is ditching American tech. When will Canada?



VASS BEDNAR >

SPECIAL TO THE GLOBE AND MAIL

PUBLISHED FEBRUARY 10, 2026

UPDATED FEBRUARY 11, 2026

Que faisons-nous lorsque le client est une banque, un organisme gouvernemental ou une entreprise dont la valeur est ses données ?

Étude de cas : Un compagnon IA d'assurance continué

La phase 1 de votre assistant d'IA a été bien accueillie et il vous est maintenant demandé de l'étendre à leur marché québécois. Vous devez faire face à des documents parfois en anglais et d'autres fois en français. Les titulaires de police d'assurance reçoivent toujours leur document de police en français au Québec, mais la société conserve également des copies de beaucoup de ces polices en anglais, mais pas toutes, car de nombreux agents de réclamations sont situés en dehors du Québec et ne parlent pas français. Comme la semaine dernière, le rôle de votre agent est toujours de : identifier (1) le type de réclamation le plus probable et (2) les sections de la politique du client qui font référence à ce type de réclamation ; puis (3) générer une évaluation initiale de l'admissibilité de la réclamation et des résolutions possibles. **En outre, l'agent devrait (4) générer une traduction de son évaluation en français à fournir aux clients ayant des réclamations en français. En ce qui concerne les documents : maintenant (i) les réclamations des clients peuvent également être en français et leurs politiques complètes cartographiées également, et environ 30 % de ces politiques ont des traductions existantes facilement disponibles (il n'y a cependant pas de traductions pour les réclamations françaises).** (ii) L'ensemble de toutes les réclamations résolues et leurs résolutions des 5 dernières années et (iii) la liste des catégories de réclamations sont toutes en anglais.

Étude de cas : Un compagnon IA d'assurance continué

- Esquissez la structure procédurale de votre assistant d'IA, en décrivant chaque étape et les technologies de TALN qui seront nécessaires. Si plusieurs sont possibles (par exemple, différents LM pourraient être utilisés), mettez en évidence lequel choisiriez-vous et pourquoi ?
- **Expliquez quelles étapes de prétraitement des données seront nécessaires pour votre solution**
- Identifiez les limites de votre solution et où elles peuvent introduire des erreurs. Quel peut être votre niveau de responsabilité et de responsabilité pour ces erreurs ?
- **Expliquez comment vous prévoyez d'évaluer votre système pendant la phase de développement et par la suite.**